



Agentic AutoML и AutoDS

Перспективные направления: аргументы за и против

Обзор ~90 работ за 2024–2026 · по 14 направлениям проверили, что уже занято · цель — демо-трек ICDM 2026

Август 2026

Условия, в которых мы выбираем

14 дней

Дедлайн ICDM 2026 Demo — 20 августа 2026, 23:59
AoE. Уведомление 20 сентября.

4 страницы

IEEE, две колонки, вместе со списком литературы.
С именами авторов. Труды — ICDMW, индексация
EI и IEEE Xplore.

CPU + API

Плюс DGX на несколько часов на задачу. Сутки на
H100 — не наш вариант.

Жёсткое требование трека: «Demos must be based on fully implemented and tested systems»

- Планка трека — не рекорд на бенчмарке, а рабочий инструмент, которым практик захочет пользоваться.
- Для калибровки: в 2024 году приняли всего около 6 демо. Формат — система с собственным именем, решающая конкретную прикладную задачу.
- Нужно приехать с постером в Шэньян 12–15 ноября. Регистрация по полному авторскому тарифу, студенческий не засчитывается.

Четыре линии — и потолок по вычислениям

A

Поиск по коду

AIDE → SELA → ML-Master → AutoMind → MLEvolve. Решение — это скрипт, механизм — поиск по дереву с правками от модели. Задаёт рекорды на MLE-bench.

B

Мультиагентные пайплайны

AutoML-Agent, MLZero, R&D-Agent, MLE-STAR и наш LightAutoDS-Tab. Роли, проверки, поиск по базе знаний. Только здесь работают поверх настоящих AutoML-библиотек.

C

Обученные агенты


ML-Agent, DeepAnalyze-8B, SandMLE, DataPRM. Модель дообучают вместо промптинга. Самая быстрорастущая линия 2026, причина — цена запросов.

D

Бенчмарки и контроль

MLE-bench, FML-bench, DSGym, TML-bench, Ambig-DS. Самые честные и самые полезные для нас выводы.

Рекорды на MLE-bench — и цена входа



Три опровергающих работы 2026 года

FML-bench

NUS · Tsinghua · Meta

«Сложность стратегии сама по себе не гарантирует высокого качества: простой жадный подъём почти не уступает лучшему агенту с поиском по дереву.»

Разнообразие решений и объём вычислений на итог не влияют.

ZIB Berlin

121 прогон · 10 672 программы

Обычная настройка гиперпараметров одной промежуточной программы сравнялась с полным эволюционным прогоном или обошла его в 13 случаях из 15.

Около 30% добавленных строк кода дословно повторяют ранее удалённые — поиск ходит по кругу.

Hutter et al.

Freiburg · Tübingen · KIT

Классические методы настройки при равном бюджете в 24 часа обошли подходы на одной только модели. Гибрид Centaur обращался к модели лишь в 30% испытаний — и выиграл.

Отдельно: выигрыш «тёплого старта» — это конфигурация по умолчанию, а не работа модели.

Вывод: идею «модель как оператор мутации» делать можно — но обязательно со сравнением при равном бюджете. Иначе разнесут на рецензии.

Где на самом деле теряется качество

Не в поиске. В отборе финальной модели и в проверках. Четыре числа из четырёх независимых работ:

+9–13 п.п.

медалей дал бы выбор финального решения по тесту, а не по валидации AIRA, Meta FAIR

$\rho = 0.71$

корреляция рангов между валидацией и тестом на 10 469 автоматических экспериментах Orze

~8 975

из 10 469 экспериментов испорчены тремя незаметными ошибками в конфигурации Orze

39–63%

случаев агент молча берётся не за ту целевую переменную, если задача неоднозначна Ambig-DS

«Агенты на языковых моделях работают на уровне постановки задачи, но не способны проверить, что реально исполнил код. Будущим автономным системам нужны автоматические тесты проверки конфигурации.»

— Orze, 2026

- DSGym: агенты сохраняют высокую точность, даже когда файлы с данными от них спрятали — часть «успеха» вообще не про данные.
- KrataBench: сокрытие входов роняет качество лишь на 15–18%.
- Отдельные проверки есть только у MLE-STAR (два контролёра) и AutoKaggle (модульные тесты) — и обе встроены внутрь своего же агента.

Все направления одним экраном

НАПРАВЛЕНИЕ	ВЕРДИКТ	ГЛАВНЫЙ АРГУМЕНТ ЗА	ГЛАВНЫЙ АРГУМЕНТ ПРОТИВ
Аудит и повторный отбор моделей	СВОБОДНО	Самый частый пробел в статьях. Не задет опровержениями.	Развитие нашей же LightAutoDS-Tab
Перемотка поиска и разбор решений	СВОБОДНО	Обзор по воспроизводимости таких систем не нашёл.	LangGraph даёт половину как обычную настройку
Агент добавляет операторы во фреймворк	ЧАСТИЧНО	Остаётся постоянный результат; отвечает на ограничение MLZero.	OMEGA (ICLR'26) неприятно близко
Управление остатком бюджета	ЧАСТИЧНО	Метод свободен. Опора: 94% разброса качества даёт архитектура.	Легко получить выигрыш в пределах случайного разброса
Точечная доработка по графу пайплайна	ЧАСТИЧНО	Проверять вклад узлов по графу дешевле, чем по коду.	Перенос приёма MLE-STAR — слишком малый шаг
Предсказание качества вместо обучения	ЧАСТИЧНО	Перенос идеи DSWorld: поиск быстрее в 3–6 раз.	Предсказатель может не работать на новых датасетах
Диагностика впустую потраченного поиска	ЧАСТИЧНО	Перенос измерений ZIB на графовый AutoML. Очень дёшево.	Это измерение, а не метод
Досье датасета (память между запусками)	ЧАСТИЧНО	Память в таких агентах привязана к задаче, к датасету — ни у кого.	Три близкие работы вышли за последние 3 месяца
Подсказки из истории прошлых запусков	ЧАСТИЧНО	Никто не использует собственную историю фреймворка.	Обе части давно известны; нужен большой эксперимент
Модель как оператор мутации в GOLEM	ЧАСТИЧНО	Ниша пуста: FEDOT/GOLEM с оператором на модели не публиковали.	SemPipes; три опровергающих работы 2026
Тёплый старт AutoML через модель	ЗАНЯТО	—	Опубликовано прямое опровержение
Разные модели на разные роли агента	ЗАНЯТО	—	BudgetMLAgent, AgentOpt и работа 2606.20629
Эволюция промптов и обвязки агента	ЗАНЯТО	—	GEPA (ICLR'26 Oral), EvoAgentX, AFlow и ещё восемь
Бенчмарк для малого бюджета	ЗАНЯТО	—	TML-bench (240/600/1200 с, ~\$10) уже занял

Вердикты получены отдельным придирчивым поиском по arXiv, OpenReview, GitHub и трудам GECCO, AutoML-Conf, KDD, ICDM.

Слой доверия: аудитор и судья

Обёртка, которая сама ничего не ищет, а проверяет чужой поиск, и работает поверх любого AutoML. Три шага: перед запуском — найти неясности в постановке и задать схему проверки; сам AutoML остаётся чёрным ящиком; после запуска — прогнать проверки на утечки и ошибки и заново выбрать модель по устойчивости, а не по оценке на валидации.

ЗА

- Закрывает две самые частые жалобы во всех статьях: разрыв между валидацией и тестом и отсутствие проверок.
- Единственная полностью свободная ниша: статические анализаторы кода и проверка рассуждений агента есть по отдельности, но над AutoML их никто не соединил.
- Мы не соревнуемся с поиском — значит три опровергающие работы 2026 года по нам не бьют.
- CPU и запросы к модели, около \$0.3 за датасет. Работает поверх FEDOT, LightAutoML, AutoGluon и обычного sklearn.
- Отлично показывается вживую: подсовываем утечку, лидер по валидации падает, наш выбор держится.

ПРОТИВ

- Это развитие нашей же LightAutoDS-Tab: в §6 мы сами написали, что хотим умный разведочный анализ против утечек. Придётся чётко показать, что здесь нового.
- Набор проверок конечен: он доказывает наличие утечки, но не её отсутствие.
- Веса в формуле отбора задаются вручную, а подбирать их на тесте нельзя — иначе теряется весь смысл.
- Есть риск, что вклад сочтут чисто инженерным, если не показать выигрыш на отложенной выборке в числах.

Перемотка поиска и разбор решений

Каждый шаг поиска — точка сохранения. Можно вернуться назад вместе с состоянием поиска и памятью агента, пойти другой веткой и в точности повторить прогон. Научная польза: можно померить, во что обошлось одно конкретное решение — сегодня этого не умеет ни одна система.

ЗА

- Самая свободная ниша из всех проверенных. Обзор по воспроизводимости в агентах (2606.04990) не нашёл ни одной системы с точным повтором прогона и ветвлением.
- Проблему признают сами авторы: CodeEvolve пишет, что точную последовательность решений повторить нельзя; в работе ZIB повтор удачных запросов даёт нулевое совпадение кода, хотя качество восстанавливается примерно на 76%.
- Отлично показывается вживую: отматываем поиск и идём другим путём прямо на глазах у зрителя.
- Естественно встраивается в аудитор как модуль — отдельная система не нужна.

ПРОТИВ

- Causal Agent Replay (июнь 2026) уже умеет вернуться к точке решения и переиграть её с учётом случайности — надо явно объяснить, чем мы отличаемся.
- LangGraph уже даёт сохранение, ветвление и продолжение как обычную настройку: половина функциональности достаётся бесплатно.
- Легко прочитать как инженерную удобность. Вклад должен быть в связке с состоянием популяции поиска плюс измеримый научный результат.

Идея руководителя: две версии

Версия 1 — «в лоб»

ЧАСТИЧНО

Языковая модель как оператор мутации внутри эволюционного цикла GOLEM над графом пайплайна.

- ЗА: ниша пуста — связку FEDOT/GOLEM с оператором на модели не публиковали нигде. Отличие от SemPipes и LMX: мы меняем типизированный граф, а не текст кода, поэтому результат корректен по построению.
- ЗА: дёшево, только CPU и запросы к модели. GOLEM позволяет подменять мутации из коробки.
- ПРОТИВ: самый высокий научный риск. Три опровергающие работы 2026 года бьют ровно сюда.
- ПРОТИВ: заметная вероятность, что честное сравнение при равном бюджете не покажет выигрыша.

Версия 2 — «Operator Forge»

ЧАСТИЧНО

Агент не переписывает код фреймворка, а расширяет его набор операторов: пишет новый элементарный оператор и регистрирует его в пространстве поиска.

- ЗА: единственная незанятая формулировка этой идеи. Остаётся постоянный результат — настоящий PR в FEDOT, что идеально ложится в требование «работающая система».
- ЗА: прямо отвечает на ограничение MLZero — «качество ограничено набором подключённых библиотек» — и на планы Хуттера по совместному развитию пространств поиска.
- ПРОТИВ: OMEGA (ICLR'26) уже собирает сгенерированные моделью алгоритмы в библиотеку. Наше отличие — регистрация оператора в пространстве поиска эволюционного AutoML.
- ПРОТИВ: возня с описанием операторов и правилами совместимости — риск не успеть за 14 дней.

Ещё четыре живых направления

1 Управление остатком бюджета

Агент перераспределяет оставшееся время между этапами: разведка данных → признаки → структура → настройка → ансамбль.

ЗА: опирается на измеренный факт — 94% разброса качества даёт архитектура и лишь 6% гиперпараметры. Метод свободен, TML-bench занял только бенчмарк.

ПРОТИВ: легко получить выигрыш в пределах случайного разброса. Нужно много запусков и доверительные интервалы.

2 Точечная доработка по графу

Дешёвая проверка вклада узлов находит самый важный узел, и модель переделывает только его.

ЗА: приём MLE-STAR стоит \$0.24 за задачу, а по графу проверять вклад узлов ещё проще и дешевле, чем по коду — это честный аргумент.

ПРОТИВ: это перенос чужого приёма, шаг небольшой. Лучше как модуль, а не как главная идея.

3 Предсказание качества вместо обучения

Маршрутизатор решает: реально обучить пайплайн или предсказать его качество по признакам датасета и структуре графа.

ЗА: перенос идеи DSWorld — обучение быстрее в 14 раз, поиск в 3–6. История запусков GOLEM сама даёт обучающую выборку.

ПРОТИВ: предсказатель может не переноситься на новые датасеты. Смягчение — предсказывать не оценку, а лучше кандидат родителя или хуже.

4 Диагностика впустую потраченного поиска

Записывать, откуда взялась каждая мутация в GOLEM, и померить, какая доля поиска ходит по кругу.

ЗА: перенос сильного измерения ZIB на графовый AutoML, где этого никто не делал. Почти без запросов к модели, очень дёшево.

ПРОТИВ: это измерение, а не метод. Само по себе тянет на воркшоп, но не на полноценный вклад.

Три направления, где мы не одни

Досье датасета

ЧАСТИЧНО

Постоянная память, привязанная к датасету и доступная человеку для правки: типы колонок, найденные утечки, группы, история пайплайнов. Устаревает сама, если данные изменились.

ЗА

Память в таких агентах привязана к задаче или навыку — к датасету ни у кого. MALMAS показателен: его память привязана к датасету, но исчезает в конце сессии.

ПРОТИВ

HASTE, CBR-R&D-Agent и EA-Graph вышли за последние три месяца и подходят с трёх сторон. Своим остаётся только привязка к датасету и автоматическое устаревание.

Подсказки из истории запусков

ЧАСТИЧНО

Посчитать, какие операторы чаще встречаются вместе в выигравших пайплайнах, и класть это знание прямо в запрос к модели.

ЗА

Никто не использует собственную историю: DS-Agent берёт разборы людей, MLE-STAR — веб-поиск. Материал уже готов: PIPES и история запусков GOLEM.

ПРОТИВ

Обе части давно известны по отдельности. После работы про пользу хороших примеров в промпте это ожидаемый ход. Нужен эксперимент со сравнением трёх вариантов.

Композитные пайплайны для рядов

ЧАСТИЧНО

Агент предлагает разложение ряда, схему лагов и связку статистики с ML; GOLEM развивает композицию. Настоящее преимущество FEDOT.

ЗА

GenAutoML и Nexus строят монолитные архитектуры — композитных эволюционных пайплайнов для рядов с агентом нет ни у кого.

ПРОТИВ

Заголовок «агентный AutoML для рядов» занят несколько раз. И это наш же заявленный план в \$6 LightAutoDS-Tab — надо согласовать внутри, кто этим занимается.

Чего делать не надо



Тёплый старт AutoML через языковую модель

Опубликовано прямое опровержение: выигрыш модели — это на самом деле конфигурация по умолчанию, а не её работа. Дайте классическому поиску тот же старт, и модель отстаёт на 0.37 п.п. к двенадцатой попытке.



Разные модели на разные роли: дешёвая разведка, сильная запись

BudgetMLAgent уже показал такой каскад в ML-агенте и -94% цены. AgentOpt (апрель 2026) подбирает модели по этапам и выдаёт границу «цена — качество». Работа 2606.20629 разбирает роли с полным анализом вклада каждой.



Эволюция промптов и обвязки агента через AutoML-оптимизатор

Ниша забита до предела: GEPA (ICLR'26 Oral), EvoAgentX, AgentSquare, AFlow, MermaidFlow, LoongFlow. Заменить AFlow на GOLEM — инженерная подмена, а не научный вклад.



Бенчмарк агентного AutoML под малый бюджет

TML-bench (март 2026) сделал ровно это: жёсткие лимиты 240 / 600 / 1200 секунд, весь набор за ~\$10. Свободен только метод, но не бенчмарк.

Что забираем у Graft и Empryo

Обе — не про данные: это контекстный слой и редактор кода для программирующих агентов. Но обе независимо пришли к одному принципу: сначала детерминированная структура, потом модель, и модель необязательна. Для ML-пайплайнов такого нет вообще — это самая пустая ниша из всех проверенных.

ПРИЁМ У НИХ

ЧТО ЭТО В НАШЕЙ ОБЛАСТИ

граф кода строится без модели, проходы модели необязательны и кэшируются

→ постоянный набор проверок, слой модели сверху необязателен, и обязательный замер: сколько даёт модель

кэш по контрольной сумме файла, обновляется только изменившееся

→ приём DS-Agent «дорого один раз, дальше дёшево» (\$1.60 → \$0.135), но на уровне датасета

радиус поражения: что сломается, если изменить узел

→ точечная доработка по типизированному графу — считается дешевле, чем по коду

важность символов по PageRank и по истории совместных правок

→ важность операторов по тому, как часто они встречаются вместе в выигравших пайплайнах

сжатие контекста по структуре, без запросов к модели

→ дешевле, чем сжатие через модель, как в EvoDS

Их способ измерять берём: агент один и тот же, меняем только контекст, в цене учитываем кэш. Их статистику — нет: у Graft на SWE-bench всего 9 задач, у Empryo раунды на 9 и 10 багах.

РЕКОМЕНДАЦИЯ

Одна система, три модуля, никакой гонки за рекордами

ядро

Аудитор и судья

Постоянный набор проверок плюс проверки, которые модель пишет под конкретный датасет. Финальный выбор — по устойчивости, а не по оценке на валидации.

модуль А

Память

Отчёт становится досье с версиями: правки человека переживают регенерацию, а находки устаревают, если данные изменились.

модуль В

Перемотка

Возврат к точке решения не как удобство, а как измерительный прибор: показать, во сколько пунктов на отложенной выборке обошлось конкретное решение.

Почему именно так

- Единственная свободная ниша из четырнадцати проверенных, и её подпирают самые сильные числа во всём обзоре.
- Мы не соревнуемся с поиском — значит три опровергающие работы 2026 года, которые убивают сюжеты вида «добавим модель в эволюцию», по нам не бьют.
- CPU и запросы к модели, работает поверх любого фреймворка, легко превращается в живое демо — а трек требует именно работающую систему.

Запасной вариант, если держаться идеи руководителя: агент, который выращивает набор операторов FEDOT.

ДО 20 АВГУСТА, 23:59 АОЕ

План на 14 дней

6–8 авг

Выбор и стенд

Окончательно выбрать направление. Собрать 15–20 датасетов: OpenML-CC18, 3–5 на регрессию, 2–3 временных ряда и 4 с заранее внедрёнными утечками. Поднять три фреймворка в одной среде.

8–13 авг

Ядро системы

Постоянные проверки, генератор проверок в песочнице, повторный отбор моделей. Адаптеры к FEDOT, LightAutoML и AutoGluon, которые достают все модели-кандидаты, а не только победителя.

12–15 авг

Интерфейс

Streamlit или Gradio — так быстрее всего. FEDOT.LLM уже на Streamlit, часть переиспользуем. Обязательно режим без интернета с кэшем: связь на площадке не гарантирована.

14–17 авг

Эксперименты

Запуски минимум на пяти случайных инициализациях с доверительными интервалами. Главная таблица: выбор по валидации против нашего выбора на отложенной выборке. Три варианта для сравнения, включая «проверки без модели».

16–19 авг

Текст

Четыре страницы в формате IEEE. Раздел про ограничения писать обязательно: в этой области его систематически пропускают, и его наличие читается как признак качества.

20 авг

Подача

Через CyberChair, одним PDF. Видео необязательно, но уйдёт на IEEE Xplore рядом со статьёй.

Итог одной строкой

Не строить ещё один AutoML-агент. Построить слой доверия над любым из них.

Область три года улучшала поиск и упёрлась в его потолок. Отбор финальной модели, проверки и воспроизводимость остались нетронутыми — при том что именно на них авторы сами указывают в каждом разделе про ограничения.

Полный отчёт: обзор ~90 работ, сводка ограничений, 14 направлений с проверкой занятости, черновик демо-статьи.